

UNIVERSITÉ CLERMONT AUVERGNE

IUT Clermont-Auvergne
Département informatique

NGUYEN Tommy FORGE Cyprien

-

Rapport de DataMining

BUT3 - Informatique

Encadrants :

Dataset utilisé : OpenFood Facts

Année universitaire : 2025 – 2026

Table des matières

1	Introduction	2
2	Exploration des données	3
3	Nettoyage des données	4
4	Réduction de dimension	5
5	Clustering	6
6	Conclusion	8

1 Introduction

Dans le cadre de notre 3ème année de BUT Informatique, nous devions réaliser un projet de DataMining qui consistait à développer une interface web à l'aide de **Streamlit**.

Lors de la première séance, nous avons dû choisir un dataset parmi tous ceux proposés par notre enseignant. Nous avons opté pour le **FIFA21 Complete Players**¹ pour la simple et bonne raison que Tommy et moi sommes deux grands amateurs de football.

Les séances suivantes se sont articulées simplement, nous prenions chacun une partie du projet et nous avançons. Le versionning de notre projet était fait avec Git.

Les tâches ont été réparties comme ceci :

- Tommy : Exploration, Visualisation des données nettoyées et Évaluation des clusters
- Cyprien : Nettoyage, Réduction de dimensions et Clustering

Pour parler plus en détails de notre dataset, il contient 18 000 lignes et 106 colonnes au format .csv. L'idée générale est que l'on retrouve tous les joueurs disponibles sur le jeu vidéo FIFA21 avec leurs différentes statistiques. Notre objectif est de pouvoir classer les joueurs en différents profils. Comme par exemple les défenseurs rugueux, les défenseurs relanceurs, les milieux créatifs, les milieux récupérateurs, etc.

Dans ce rapport, nous allons vous raconter tout le processus par lequel nous sommes passés d'un simple dataset à une analyse complète, étape par étape, en commentant chaque choix méthodologique.

1. <https://www.kaggle.com/datasets/stefanoleone992/fifa-21-complete-player-dataset?resource=download>

2 Exploration des données

Avant de commencer à traiter de la donnée, il faut bien évidemment en avoir. C'est l'enjeu principal de cette phase d'exploration des données. Notre application Streamlit propose de pouvoir drag and drop le dataset de votre choix.

Le premier problème auquel nous avons été confronté est la différence entre les gardiens et les joueurs de champs. En effet, tous les gardiens n'ont pas de statistiques relatifs aux joueurs de champs, et inversement. Pour nous simplifier la tâche, dans un premier temps, nous avons décidé de retirer toutes les lignes de gardien de but et toutes les colonnes relatives aux statistiques de ce poste.

Nous avons aussi supprimé des lignes au préalable, avant le nettoyage. Parmi elles on retrouve les colonnes relatives aux numéros de maillot qui n'ont aucun intérêt pour notre analyse, ainsi que la nationalité de chaque joueur, sa valeur marchande ou son salaire. Nous souhaitons prendre en compte uniquement les qualités intrinsèques du joueur relatives uniquement à son niveau footballistique.

Après cela on arrive à 16860 lignes et 49 colonnes.

3 Nettoyage des données

Après cette phase d'exploration, nous devons nettoyer nos données pour pouvoir les exploiter au mieux. Cette phase est paramétrable grâce à Streamlit, chacun peut donc nettoyer le dataset comme il le souhaite mais voici que nous, nous recommandons :

Détection des valeurs manquantes : nous n'avons aucune valeurs manquantes sur nos 16 000 lignes 49 colonnes, ce qui facilite le traitement

Détection et traitement des outliers : ici, nous sommes face à un gros dilemme qui nous a amusé lors de la réalisation de ce projet. Des joueurs comme Lionel Messi ou Cristiano Ronaldo sont considérés comme des outliers aux yeux des algorithmes z-score ou IQR. Même avec un seuil à $z = 0$ où un multiplicateur à 3 pour l'IQR. Nous avons décidé ne pas traiter les outliers car nous voulons que notre dataset reste peuplé par les meilleurs joueurs de la planète, qui par leur exceptionnel niveau sont considérés comme des anomalies.

Encodage des variables qualitatives : on retrouve 4 variables qualitatives : le nom, le prénom, le pied fort du joueur et l'intensité que met le joueur en phase offensive ou en phase défensive. Le nom et le prénom ne sont qu'à titre indicatif et n'ont aucun impact sur notre analyse. Nous encodons seulement le pied fort et l'intensité. Nous sommes ici avec des variables qualitatives nominales, ainsi un One-Hot Encoding est plus adapté.

Normalisation des données : pour pouvoir appliquer une réduction de dimension ACP il est primordial de normaliser les données. L'ACP se base sur la variance, d'où le besoin de normaliser. Nous donnons la possibilité de normaliser via la méthode Min-Max, via le Z-Score ou via RobustScaler. Étant donné que nous avons une centaine d'outliers comme expliqué plus haut, nous optons, personnellement, pour le RobustScaler

4 Réduction de dimension

Afin de gagner en précision et pouvoir visualiser nos données sur un plan en 2D, nous avons procédé à une réduction de dimension.

Nous implémenter 3 algorithmes : ACP, Isomap et Kernel-CPA. ACP nous permet d'obtenir une visualisation en 2D comme celle-ci :




FIGURE 1 – Projection des individus en 2D après ACP

Cet axe peut-être interprété comme ceci : plus le point a un abscisse (x) élevée plus le joueur est créatif, avec de bonnes qualités de passe, de dribble et de contrôle de balle. Plus le point a une ordonnée (y) élevée plus le joueur est solide défensivement et physique avec de bonnes qualités de tackle, de physique et de jeu aérien.

Nous avons procédé aussi à une réduction via Isomap qui est une méthode non-linéaire contrairement à ACP. La faible variance expliquée par les premières composantes de l'ACP suggère la présence de structures non linéaires dans les données. Kernel PCA a donc été retenue, sous conseil de notre professeur afin de mieux représenter ces relations et d'obtenir une réduction de dimension plus pertinente.

5 Clustering

Le clustering est le point clé de notre projet, c'est ici que l'on va pouvoir extraire les profils de chaque joueur via ses statistiques.

Nous proposons de faire cela avec algorithmes : K-Means (prototype), DBSCAN (densité) et Spectral Clustering. Nous allons nous concentrer sur les résultats du K-Means. Avec $k = 3$, nous obtenons un tel clustering :




FIGURE 2 – Résultats du K-Means avec $k = 3$

L'interprétation est simple :

- Cluster 0 : Joueur créatif avec des qualités de passe et de contrôle de balle ==> **Lionel Messi**
- Cluster 1 : Joueur défensif avec des qualités de tacles glissés, tacles debout et défense ==> **Virgil Van Dijk**
- Cluster 2 : Joueur finisseur avec des qualités de vitesse, accélération et finition ==> **Kylian Mbappé**

Nous sommes capable de regrouper les joueurs dans 3 types, qui sont globalement : défenseurs, milieux et attaquants.

Pour pouvoir aller encore plus loin dans l'analyse et identifier des profils plus complexes nous procédons à un K-Means avec $k = 5$.




FIGURE 3 – Résultats du K-Means avec $k = 5$

- Cluster 0 : Joueur offensif avec une bonne finition, une grande qualité de frappes et reprise de volées mais très faible défensivement ==> **Youssef En-Nesyri**
- Cluster 1 : Joueur doté de bonnes qualités athlétiques mais moins footballistiques ==> **J. Marx**
- Cluster 2 : Joueur créatif avec des qualités de passes et de contrôle de balle ==> **Lionel Messi**
- Cluster 3 : Joueur défensif grand et costaud avec des qualités défensives ==> **Niklas Süle**
- Cluster 4 : Joueur défensifs avec de bonnes qualités d'interception, de défense et de tackle glissés ==> **Kalidou Koulibaly**

6 Conclusion

Ce projet nous permet de pouvoir identifier quelques profils types de joueurs à partir de leurs statistiques sur le jeu FIFA21 comme nous l'avons montré dans la partie précédente.

Ce projet a été une bon fin pour la ressource de DataMining, afin de mettre en pratique l'ensemble des connaissances obtenues. Nous avons été limité par le nombre d'heures pour réaliser ce projet.

Nous aurions voulu ajouter la possibilité de pouvoir générer aléatoirement des joueurs de profil précis, ou inversement pouvoir créer son propre joueur et lui assigner automatiquement un profil grâce à notre clustering.